어노테이션 예비 검증 보고서

RTN-PV-2026-001 (v1.0) · 생성 2026-10-31 03:12

⚠️ 본 문서는 **보고서 형식 시연용 견본**이며, 모든 수치와 사례는 가상 데이터로 자동 생성되었습니다.

검정 플랫폼 export에서 자동 산출 **빨강** 전문의가 직접 입력·확인

파랑 LLM을 연결하면 초안 작성 (전문의 검토 후 확정)

표지

항목	내용
보고서 번호	RTN-PV-2026-001 (v1.0)
의뢰 기관	○○ AI (가칭)
대상 AI	OCT 삼출성 액체(IRF·SRF) 분할 AI v2.3 (원 학습 장비: 장비 A)
검증 목적	신규 장비 B로 촬영한 OCT에서 의뢰 AI의 삼출성 액체 검출 성능을 본 검증 전에 확인
데이터	OCT 장비 B 예비검증 (R1) — 400장 (oct)
수행 기간	7주 (2026-09-15 – 2026-10-31)
수행 기관	레티노베이션 (Retinnovation)
판독 책임자	황○○ (망막 전문의, 판독 책임자)
원자료	primary.zip (export 2026-10-27T10:00:00Z, oct-platform-export/1)

1. 요약 (Executive Summary)

- 400장 중 **380장(95.0%)**이 판독 가능, 20장(5.0%)은 판독 불가로 분류됐습니다.
- R1·R2 독립 판독(n=70)의 엔드포인트 일치율은 **98.6%, κ 0.96**, 평균 Dice 0.836였습니다. 라벨 단위 불일치 15건 중 15건은 R3가 조정했습니다.
- AI의 삼출성 액체 (IRF 또는 SRF) 판별 성능은 **민감도 76.4%, 특이도 93.0%**였습니다.
- 성능 저하는 주로 **화질 경계**(민감도 65.4%), **연령 65세 이상**(민감도 69.0%)에서 나타났습니다.
- 위음성 26건 중 9건이 **영상 가장자리 병변 (스캔 범위 경계)**와 관련됐습니다.
- 본 검증 진행 전, **저성능 구간 양성 사례 약 320장 추가 확보 · 촬영 프로토콜 보완 · 화질 필터 임계값 재조정**을(를) 권고합니다.

장비 B 영상에서 의뢰 AI의 삼출성 액체 민감도(76.4%)는 장비 A 기준값(93.0%)보다 낮고, 특이도(93.0%)는 비슷했습니다. 저하는 화질 경계 영상과 65세 이상에서 두드러지며, 위음성의 상당수가 스캔 가장자리 병변과 소형 병변에서 나왔습니다. 판독자 간 일치도가 높아(κ 0.96) 라벨 자체의 신뢰도는 충분하므로, 성능 차이는 장

비 변경에 따른 AI 쪽 원인으로 보입니다. 현재 상태로 본 검증에 들어가면 민감도 기준을 넘기 어려울 가능성이 높아, 저성능 구간 데이터 보강과 촬영 프로토콜 보완 후 진행하는 것을 권합니다.

---

2. 범위와 방법

2.1 판독 기준

- 라벨 체계: IRF SRF Drusen and drusenoid PED Other PED Hyperreflective foci SHRM Fibrotic HRM / subretinal fibrosis Microaneurysm-like lesion
- 엔드포인트 **삼출성 액체 (IRF 또는 SRF)**: IRF, SRF 중 하나 이상 존재
- 병변 '있음' 기준: 해당 라벨 마스크 30px 이상 · 판독자 간 불일치: 병변 유무 불일치 또는 엔드포인트 Dice < 0.5
- 판독 불가 기준: 신호 약함(저대비), 노출 과다(포화), 초점 불량(흐림) — 판독자가 화질을 지정한 영상은 그 값을 우선
- 라벨별 판독 정의(SOP): IRF: 신경감각망막 내 저반사 낭포성 공간. SRF: 신경감각망막과 RPE 사이 저반사 공간. 드루젠 융기 아래 저반사는 액체로 보지 않음. 엔드포인트는 활동성 nAMD 판단 근거인 삼출성 액체 존재 여부. 망막층 구분이 불가능한 영상은 판독 불가.

2.2 판독 절차

단계	내용	대상
영상 QC	비식별 확인, 화질 3단계(양호/경계/불가) 분류 — 자동 화질 지표 + 판독자 지정	400장
1차 판독	R1 전수 판독 (reader_kim, reader_lee)	380장
2차 판독	R2 독립 판독 (reader_park), 표본 18.4%	70장
불일치 조정	R3가 R1·R2 불일치 건을 판정	15건 / 불일치 15건
AI 비교	확정 라벨과 의뢰 AI 결과 비교	380장

- 맹검 여부: 판독자는 플랫폼에서 AI 예측과 타 판독자 결과를 볼 수 없는 계정으로 판독함 (점·윤곽 보조는 자기 프롬프트에만 반응). 판독 모니터 27인치, 확대·밝기 조절 허용.
- AI 보조 도구(점·윤곽 프롬프트)는 영역 제안에만 사용했으며 (75장, 19.7%), 마스크는 판독자가 최종 확정했습니다.

---

3. 영상 QC 결과



● 양호 **68.2%** ▲ 경계 (판독 가능) **26.8%** ✕ 판독 불가 **5.0%**

분류	장수	비율
● 양호	273	68.2%
▲ 경계 (판독 가능)	107	26.8%
✕ 판독 불가	20	5.0%
합계	**400**	**100%**

판독 불가 사유: 신호 약함 (저대비) 20

분류 근거: 판독자 지정 0건, 자동 화질 지표 400건

화질 확인: 판독 불가 20건 전수, 경계 107건 중 30건 표본 확인 — 자동 분류와 모두 일치.

4. 판독자 간 일치도 (R1 vs R2, n=70)

지표	삼출성 액체 (IRF 또는 SRF) (엔드포인트)
완전 일치율	98.6% (69/70)
Kappa (Cohen)	0.96
평균 Dice	0.836 (n=18)
불일치 건수 (유무 또는 Dice 기준)	15

라벨	R1 양성	R2 양성	일치율	κ	평균 Dice (n)
IRF	7	6	98.6%	0.92	0.716 (7)
SRF	15	15	100.0%	1.0	0.893 (15)
Drusen and drusenoid PED	24	17	90.0%	0.76	0.592 (24)
Hyperreflective foci	8	5	90.0%	0.41	0.319 (15)

두 판독자 모두 양성이 없는 라벨 4개는 생략했습니다.

→ 불일치 15건 중 15건은 R3 조정으로 확정했으며, 이력은 부록 A에 기록했습니다.

5. AI 성능 (기준: 확정 라벨, n=380)

	확정 양성 (110)	확정 음성 (270)
AI 양성	84 (TP)	19 (FP)
AI 음성	26 (FN)	251 (TN)

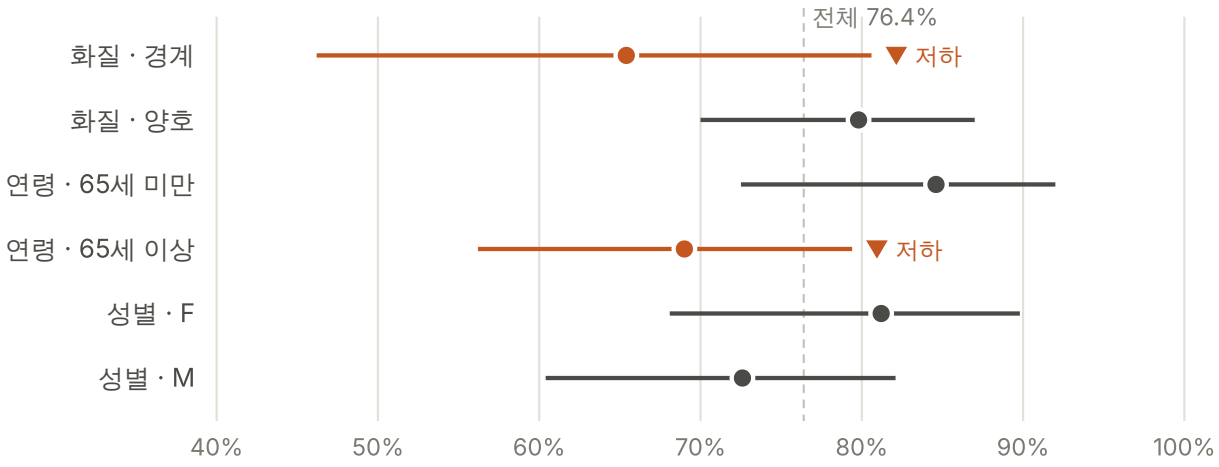
지표	본 검증	기준값 (원 학습 장비)
민감도	76.4% (95% CI 67.6–83.3)	93.0% (의뢰사 내부 검증, n=1,200)
특이도	93.0% (95% CI 89.3–95.4)	91.0% (의뢰사 내부 검증, n=1,200)
평균 Dice (TP)	0.814	—

라벨별 성능

라벨	확정 양성	TP	FN	FP	민감도 (95% CI)	특이도 (95% CI)	평균 Dice
IRF	56	34	22	14	60.7% 47.6–72.4	95.7% 92.9–97.4	0.789
SRF	87	65	22	9	74.7% 64.7–82.7	96.9% 94.3–98.4	0.861
Drusen and drusenoid PED	127	101	26	1	79.5% 71.7–85.6	99.6% 97.8–99.9	0.739
Hyperreflective foci	45	10	35	9	22.2% 12.5–36.3	97.3% 95.0–98.6	0.778

확정 양성과 AI 양성이 모두 없는 라벨 4개는 생략했습니다.

6. 서브그룹 분석 (민감도)



서브그룹	영상 수	양성	TP	민감도	특이도
화질 · 경계	107	26	17	▼ 65.4%	92.6%
화질 · 양호	273	84	67	79.8%	93.1%
연령 · 65세 미만	174	52	44	84.6%	92.6%
연령 · 65세 이상	206	58	40	▼ 69.0%	93.2%
성별 · F	189	48	39	81.2%	90.8%
성별 · M	191	62	45	72.6%	95.3%

ℹ️ ▼ 표시는 전체 민감도보다 5%p 이상 낮은 구간입니다. 서브그룹 표본 수가 작아 신뢰구간이 넓습니다. 본 결과는 경향 확인용이며 통계적 결론으로 해석하지 않습니다.

7. 오류 분석

위음성 (FN, 26건)

원인 (자동 분류)	건수	예시	판독자 소견
영상 가장자리 병변 (스캔 범위 경계)	9	OCT-0002.png, OCT-0150.png, OCT-0182.png	장비 B의 스캔 폭이 좁아 주변부 SRF가 영상 가장자리에 걸림. 중심와 영향이 없는 소량이 대부분.
경계 화질 (저대비·잡음)	8	OCT-0041.png, OCT-0134.png, OCT-0186.png	신호가 약한 영상에서 저반사 공간과 배경 대비가 낮아 IRF 경계가 불분명함.
소형 병변	6	OCT-0107.png, OCT-0228.png, OCT-0248.png	직경 100 µm 미만의 소형 IRF. 임상적으로 놓쳐도 치료 결정은 바뀌지 않는 수준.
기타	3	OCT-0057.png, OCT-0095.png, OCT-0256.png	드루젠 인접 SRF로 경계 판단이 어려운 사례.

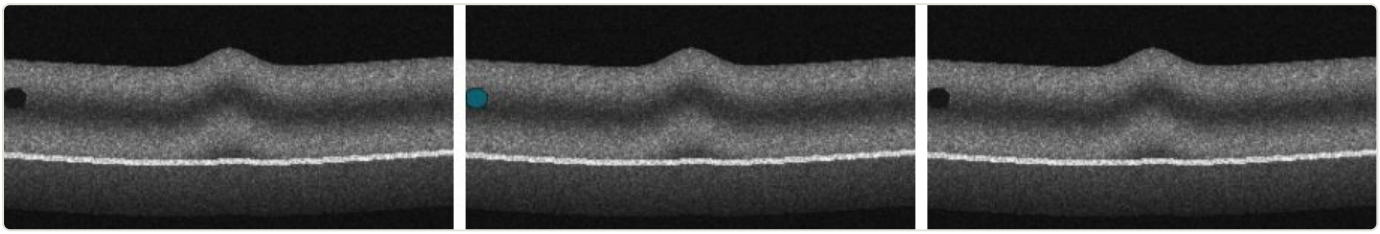
위양성 (FP, 19건)

원인 (자동 분류)	건수	세부	판독자 소견
타 병변과 혼동	8	Drusen and drusenoid PED 8	RPE 위로 솟은 드루젠 내부의 저반사를 SRF로 예측함. 장비 B에서 드루젠 내부 반사가 더 낮게 보임.
경계 화질 artifact	4	—	잡음이 많은 영상의 저반사 반점을 IRF로 예측함.
소형 위양성 (잡음)	7	—	1–2 픽셀 크기의 잡음성 예측. 후처리(최소 크기)로 제거 가능.

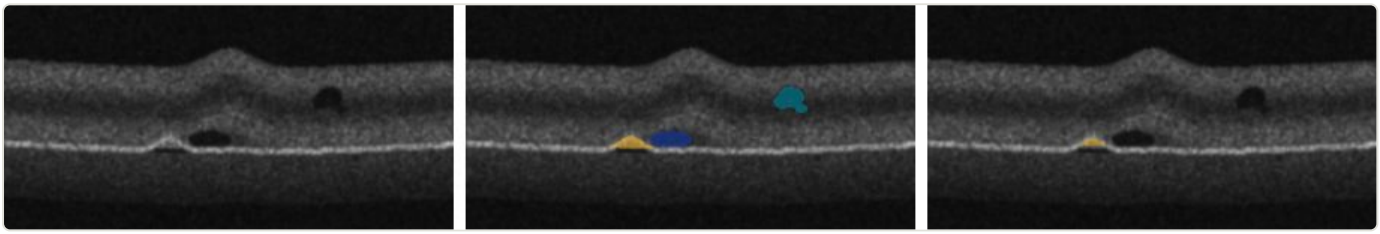
위음성은 영상 가장자리, 경계 화질, 소형 병변 순으로 많았고, 세 원인 모두 병변 신호가 약하거나 일부만 보이는 경우입니다. 위양성의 약 40%는 드루젠을 SRF로 예측한 사례로, 장비 B에서 드루젠 내부 반사가 낮게 보이는 특성과 관련이 있어 보입니다. 나머지 위양성은 대부분 잡음성 소형 예측이라 최소 크기 후처리로 줄일 수 있습니다.

오류 사례

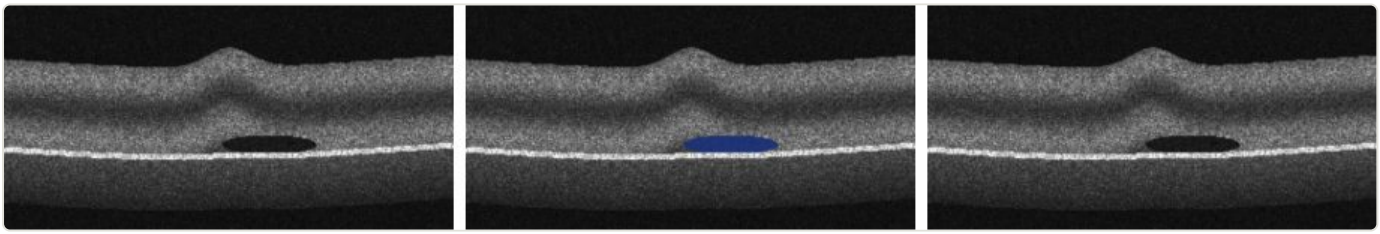
각 사례: 원본 | 확정 라벨 | AI 예측 (라벨 색은 2.1 참조)



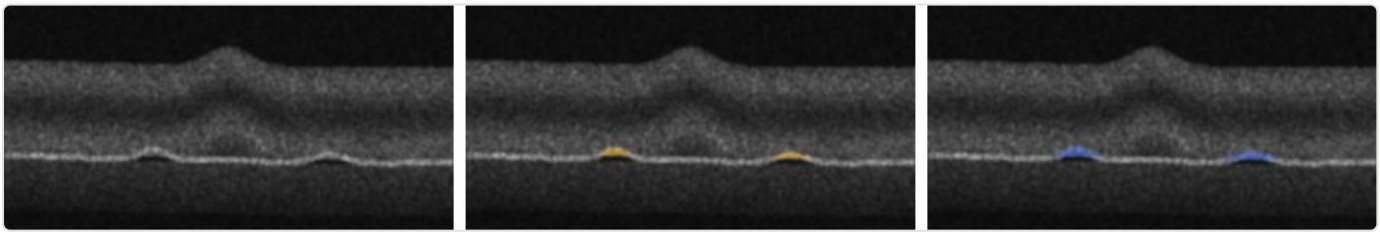
FN OCT-0002.png — 영상 가장자리 병변 (스캔 범위 경계)
판독자 소견: 스캔 가장자리 소량 액체, 중심와 영향 없음



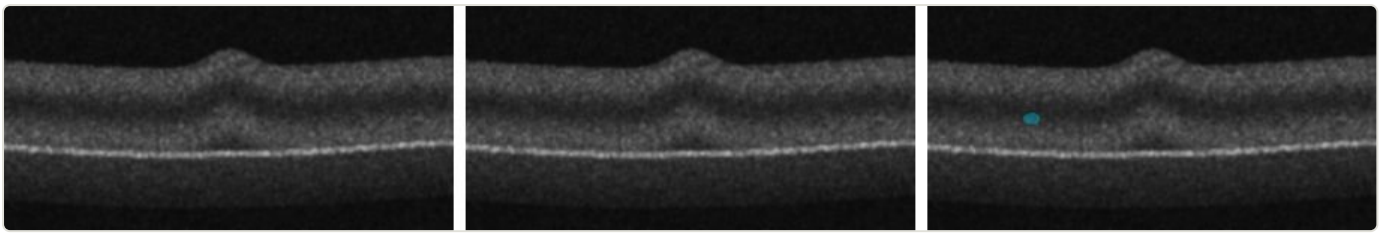
FN OCT-0041.png — 경계 화질 (저대비·잡음)
판독자 소견: 신호 약한 영상에서 저반사 공간 대비 낮음



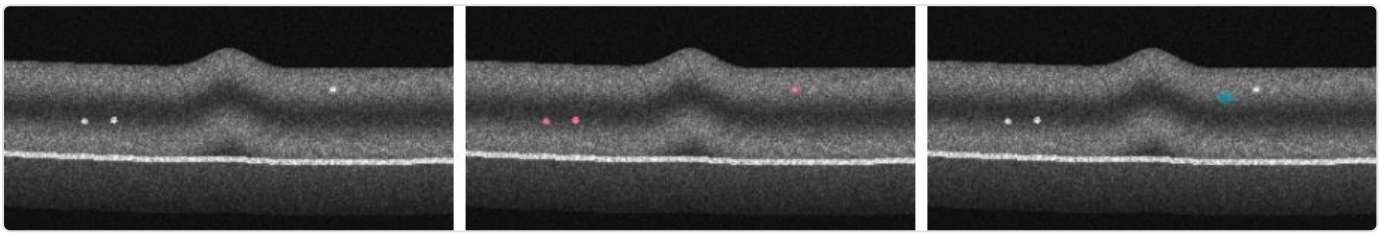
FN OCT-0057.png — 기타
판독자 소견: 드루젠 인접 SRF, 경계 판단 어려움



FP OCT-0001.png — 타 병변과 혼동 — Drusen and drusenoid PED
판독자 소견: RPE 위 드루젠 융기, 액체 아님



FP OCT-0017.png — 경계 화질 artifact
판독자 소견: 잡음이 많은 영상의 저반사 반점



FP OCT-0023.png — 소형 위양성 (잡음)
판독자 소견: 잡음성 소형 예측

---

8. 권고사항

1. **추가 데이터**: 민감도가 낮은 구간(연령 65세 이상, 화질 경계)의 양성 사례 약 320장을 추가 확보해 재학습 또는 보정 검토 (95% CI ±5%p 기준)
2. **촬영 프로토콜**: 위음성 9건이 스캔 가장자리 병변 — 스캔 범위·중심 고정 가이드 보완
3. **화질 필터**: 판독 불가 5.0%, 경계 화질에서 성능 저하 — AI의 판독 불가 판정 임계값 재조정 검토
4. **특이도**: 위양성 중 타 병변 혼동(Drusen and drusenoid PED 8건) — 해당 병변 혼재 사례를 학습 데이터에 보강
5. **판독 기준**: 판독자 간 일치도가 낮은 라벨(Hyperreflective foci κ 0.41) — SOP 정의 보완 및 판독자 재교육
6. **데이터 정제**: 중복 영상 1쌍, 유사 중복 1쌍 — 학습·검증 세트 간 누수 확인
7. **다음 단계**: 위 보완 후 표준 검증(2인 전수 판독) 또는 reading center 본 검증 진행

추가 데이터는 65세 이상과 경계 화질 영상의 양성 사례에 집중해야 하며, 95% 신뢰구간을 ±5%p로 좁히려면 해당 구간 양성 약 320장이 필요합니다. 촬영 프로토콜은 스캔 폭을 넓히거나 중심와를 영상 중앙에 고정하도록 안내하면 가장자리 위음성을 줄일 수 있습니다. 화질 필터는 AI가 신호 약한 영상을 '판독 불가'로 돌려보내는 임계값을 높이는 방향을 검토하고, 드루젠 혼동은 장비 B 드루젠 사례를 학습 데이터에 추가해 보완할 수 있습니다.

판독 책임자 검토 의견: 1–4번 권고 동의. 추가 확보 장수는 의뢰사와 협의해 150장부터 시작하고, 5번(판독 기준)은 HRF 정의를 SOP v1.1에 반영함.

---

9. 해석 범위와 한계

- 본 보고서는 **예비 검증(pre-validation)** 결과이며, 규제기관 제출용 임상 성능 평가를 대체하지 않습니다.
- 제2 판독은 18.4% 표본(70/380)에만 수행했으므로, 나머지 81.6%의 라벨은 단일 판독 기반입니다.

- 화질 분류 중 400건은 자동 화질 지표(신호 강도·포화·선명도)로 산출했으며, 판독자 확인 전 참고값입니다.
- 병변 유무는 해당 라벨 픽셀이 30px 이상일 때 '있음'으로 판정했습니다. Dice는 두 마스크 중 하나라도 병변이 있는 영상에서만 계산했습니다.
- 서브그룹 표본 수가 작아 신뢰구간이 넓습니다. 서브그룹 결과는 경향 확인용이며 통계적 결론으로 해석하지 않습니다.
- 결과는 의뢰사가 제공한 데이터의 분포에 한정되며, 다른 기관·인구집단으로 일반화할 수 없습니다.
- 레티노베이션 (Retinnovation)은(는) 의뢰 AI의 성능을 보증하지 않으며, 판독 절차와 결과 기록의 정확성에 대해 책임집니다.

부록 A. 불일치 조정 이력

영상 ID	R1	R2	확정	Dice	조정 근거
OCT-0016.png	Drusen and drusenoid PED	병변 없음	Drusen and drusenoid PED, Hyperreflective foci	—	RPE 융기 확인, 드루젠 포함
OCT-0022.png	Drusen and drusenoid PED	병변 없음	Drusen and drusenoid PED	—	RPE 융기 확인, 드루젠 포함
OCT-0045.png	IRF, SRF, Drusen and drusenoid PED	IRF, SRF	IRF, SRF, Drusen and drusenoid PED	0.91	RPE 융기 확인, 드루젠 포함
OCT-0087.png	Hyperreflective foci	병변 없음	Hyperreflective foci	—	HRF 2개 이상 확인
OCT-0093.png	IRF	병변 없음	IRF, Hyperreflective foci	0.0	소형 IRF 확인 (R2 누락)
OCT-0126.png	SRF, Hyperreflective foci	SRF	SRF, Hyperreflective foci	0.9	HRF 2개 이상 확인
OCT-0152.png	Drusen and drusenoid PED	Drusen and drusenoid PED, Hyperreflective foci	Drusen and drusenoid PED, Hyperreflective foci	—	HRF 2개 이상 확인
OCT-0157.png	Hyperreflective foci	병변 없음	Hyperreflective foci	—	HRF 2개 이상 확인
OCT-0179.png	Drusen and drusenoid PED	병변 없음	Drusen and drusenoid PED, Hyperreflective foci	—	RPE 융기 확인, 드루젠 포함
OCT-0217.png	Drusen and drusenoid PED	병변 없음	Drusen and drusenoid PED, Hyperreflective foci	—	RPE 융기 확인, 드루젠 포함

영상 ID	R1	R2	확정	Dice	조정 근거
OCT-0244.png	Drusen and drusenoid PED	병변 없음	Drusen and drusenoid PED	—	RPE 융기 확인, 드루젠 포함
OCT-0261.png	SRF, Hyperreflective foci	SRF	SRF, Hyperreflective foci	0.92	HRF 2개 이상 확인
OCT-0291.png	SRF, Drusen and drusenoid PED	SRF	SRF, Drusen and drusenoid PED	0.72	RPE 융기 확인, 드루젠 포함
OCT-0302.png	Drusen and drusenoid PED	Drusen and drusenoid PED, Hyperreflective foci	Drusen and drusenoid PED, Hyperreflective foci	—	HRF 2개 이상 확인
OCT-0399.png	Drusen and drusenoid PED, Hyperreflective foci	Drusen and drusenoid PED	Drusen and drusenoid PED, Hyperreflective foci	—	HRF 2개 이상 확인

부록 B. 판독자 정보

ID	역할	자격	SOP 교육 이수	골드스탠다드 일치도 (κ)	판독 수	확정 라벨 대비 κ
reader_kim	R1	안과 전문의 (망막)	2026-10-06	0.89	192	1.0
reader_lee	R1	안과 전문의 (망막)	2026-10-06	0.87	188	1.0
reader_park	R2	안과 전문의	2026-10-07	0.85	70	0.96
reader_r3	R3	망막 전문의 (판독 책임자)	SOP 작성자	기준 판독자	15	—

부록 C. 데이터 처리

- 영상 무결성: SHA-256 기록 400장 · 목록 해시 `e180a3c9a6205b7d…`
- 중복 점검: 동일 파일 1쌍, 유사 중복(미세 구조 상관 ≥ 0.99) 1쌍 — OCT-0172.png↔OCT-0212.png

- 수령 시 비식별 상태 재확인 (DICOM 태그·영상 내 텍스트), 접근 권한은 판독자·QC 담당자로 한정하고 플랫폼 이벤트 로그 보관, 원본 영상은 계약 종료 후 30일 내 파기 및 파기 확인서 발급
- 납품물: 본 보고서(HTML/PDF), 라벨 원자료(platform export zip: masks/, points/, lines/, annotations.json), 영상별 결과(cases.csv), 집계 원자료(report.json)

확인 및 서명

역할	성명	서명	일자
판독 책임자 (R3)	황○○	(서명)	2026-10-30
QC 담당자	최○○	(서명)	2026-10-30